


REPASO


Bayes

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$


posterior *likelihood* *prior*

REPASO

Bayes

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$


posterior *likelihood* *prior*

prior predictive $p(y) = \int p(y|\theta)p(\theta)d\theta$

REPASO

Bayes

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$

posterior *likelihood* *prior*

prior predictive $p(y) = \int p(y|\theta)p(\theta)d\theta$

posterior predictive $p(\tilde{y}|y) = \int p(\tilde{y}|\theta)p(\theta|y)d\theta$

REPASO

Bayes

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$

posterior *likelihood* *prior*

prior predictive $p(y) = \int p(y|\theta)p(\theta)d\theta$

posterior predictive $p(\tilde{y}|y) = \int p(\tilde{y}|\theta)p(\theta|y)d\theta$

Modelo moneda

Modelo Gaussiana (media, varianza)

Otras distribuciones

Binomial \longrightarrow Beta

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

$$p(y|\theta) = \frac{\theta^y e^{-\theta}}{y!} \quad y = 0, 1, 2, \dots$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

$$p(y|\theta) = \frac{\theta^y e^{-\theta}}{y!} \quad y = 0, 1, 2, \dots$$

$$p(y|\theta) = \prod_{i=1}^n \frac{\theta^{y_i} e^{-\theta}}{y_i!} \propto \theta^{n\bar{y}} e^{-n\theta}$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

$$p(y|\theta) = \frac{\theta^y e^{-\theta}}{y!} \quad y = 0, 1, 2, \dots$$

$$p(y|\theta) = \prod_{i=1}^n \frac{\theta^{y_i} e^{-\theta}}{y_i!} \propto \theta^{n\bar{y}} e^{-n\theta}$$

$$p(\theta) = \Gamma(\alpha, \beta)$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

$$p(y|\theta) = \frac{\theta^y e^{-\theta}}{y!} \quad y = 0, 1, 2, \dots$$

$$p(y|\theta) = \prod_{i=1}^n \frac{\theta^{y_i} e^{-\theta}}{y_i!} \propto \theta^{n\bar{y}} e^{-n\theta}$$

$$p(\theta) = \Gamma(\alpha, \beta)$$

$$p(\theta|y) = \Gamma(\alpha + n\bar{y}, \beta + n)$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \nearrow \text{Gaussiana (media)} \\ \searrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

$$p(y|\theta) = \frac{\theta^y e^{-\theta}}{y!} \quad y = 0, 1, 2, \dots$$

$$p(y|\theta) = \prod_{i=1}^n \frac{\theta^{y_i} e^{-\theta}}{y_i!} \propto \theta^{n\bar{y}} e^{-n\theta}$$

$$p(\theta) = \Gamma(\alpha, \beta)$$

$$p(\theta|y) = \Gamma(\alpha + n\bar{y}, \beta + n)$$

cuentas observaciones

\nwarrow \nearrow

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

$$p(y|\theta) = \theta e^{-y\theta} \quad y > 0$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

$$p(y|\theta) = \theta e^{-y\theta} \quad y > 0$$

$$p(y|\theta) = \Gamma(1, \theta)$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

$$p(y|\theta) = \theta e^{-y\theta} \quad y > 0$$

$$p(y|\theta) = \Gamma(1, \theta)$$

$$p(y|\theta) = \theta^n e^{-n\bar{y}\theta}$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

$$p(y|\theta) = \theta e^{-y\theta} \quad y > 0 \qquad p(\theta) = \Gamma(\alpha, \beta)$$

$$p(y|\theta) = \Gamma(1, \theta)$$

$$p(y|\theta) = \theta^n e^{-n\bar{y}\theta}$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

$$p(y|\theta) = \theta e^{-y\theta} \quad y > 0$$

$$p(\theta) = \Gamma(\alpha, \beta)$$

$$p(y|\theta) = \Gamma(1, \theta)$$

$$p(\theta|y) = \Gamma(\alpha + n, \beta + n\bar{y})$$

$$p(y|\theta) = \theta^n e^{-n\bar{y}\theta}$$

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

$$p(y|\theta) = \theta e^{-y\theta} \quad y > 0$$

$$p(\theta) = \Gamma(\alpha, \beta)$$

$$p(y|\theta) = \Gamma(1, \theta)$$

$$p(\theta|y) = \Gamma(\alpha + n, \beta + n\bar{y})$$

$$p(y|\theta) = \theta^n e^{-n\bar{y}\theta}$$

observaciones \swarrow tiempo de espera total

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

Otras distribuciones

Binomial \longrightarrow Beta

Gaussiana $\begin{cases} \longrightarrow \text{Gaussiana (media)} \\ \longrightarrow \text{Gamma inversa (varianza)} \end{cases}$

Poisson (cuentas) \longrightarrow Gamma

Exponencial (tiempos) \longrightarrow Gamma

Bloques para modelos más complejos

...¿más variables?

Gaussiana “completa”

$$p(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2} (y-\mu)^2}$$

Gaussiana “completa”

$$p(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2} (y-\mu)^2}$$

prior conjugado

$$p(\mu, \sigma^2) = p(\mu|\sigma^2)p(\sigma^2)$$

Gaussiana “completa”

$$p(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(y-\mu)^2}$$

prior conjugado

$$p(\mu, \sigma^2) = p(\mu|\sigma^2)p(\sigma^2)$$

$$\mu|\sigma^2 \sim \text{N}(\mu_0, \sigma^2/\kappa_0)$$

$$\sigma^2 \sim \text{Inv-}\Gamma(\alpha_0, \beta_0)$$

Gaussiana “completa”

$$p(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(y-\mu)^2}$$

prior conjugado

$$p(\mu, \sigma^2) = p(\mu|\sigma^2)p(\sigma^2)$$

$$\mu|\sigma^2 \sim \text{N}(\mu_0, \sigma^2/\kappa_0)$$

$$\sigma^2 \sim \text{Inv-}\Gamma(\alpha_0, \beta_0)$$

prior semiconjugado

$$\mu|\sigma^2 \sim \text{N}(\mu_0, \tau_0)$$

Gaussiana “completa”

$$p(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(y-\mu)^2}$$

prior conjugado

$$p(\mu, \sigma^2) = p(\mu|\sigma^2)p(\sigma^2)$$

$$\mu|\sigma^2 \sim \text{N}(\mu_0, \sigma^2/\kappa_0)$$

$$\sigma^2 \sim \text{Inv-}\Gamma(\alpha_0, \beta_0)$$

prior semiconjugado

$$\mu|\sigma^2 \sim \text{N}(\mu_0, \tau_0)$$

$$p(\mu, \sigma^2) = p(\mu)p(\sigma^2)$$

Gaussiana “completa”

$$p(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(y-\mu)^2}$$

prior conjugado

$$p(\mu, \sigma^2) = p(\mu|\sigma^2)p(\sigma^2)$$

$$\mu|\sigma^2 \sim N(\mu_0, \sigma^2/\kappa_0)$$

$$\sigma^2 \sim \text{Inv-}\Gamma(\alpha_0, \beta_0)$$

prior semiconjugado

$$\mu|\sigma^2 \sim N(\mu_0, \tau_0)$$

$$p(\mu, \sigma^2) = p(\mu)p(\sigma^2)$$

No da un resultado estándar, pero puede ser útil, y más apropiado según el problema (si tenemos una estimación de μ independiente de la forma de producir muestras)

Gaussiana multivariada

$$p(y|\mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} (y-\mu)^T \Sigma^{-1} (y-\mu)}$$

μ d -vector

Σ matriz $d \times d$ simétrica y definida positiva

Gaussiana multivariada

$$p(y|\mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} (y-\mu)^T \Sigma^{-1} (y-\mu)}$$

μ d -vector

Σ matriz $d \times d$ simétrica y definida positiva

Similar al caso $d = 1$

Covarianza conocida: *prior* conjugado Gaussiano


Posterior marginales: también Gaussianas

De vuelta a la binomial.. ahora con n desconocido

$$k \sim \text{Binomial}(\theta, n)$$

$$\theta \sim \text{Uniforme}(0, 1)$$

$$n \sim \text{Uniforme}(1, N_{max})$$



$$p(\theta, n|k) = \dots$$


Ejemplo con varias observaciones (encuesta)

$$k_i \sim \text{Binomial}(\theta, n)$$


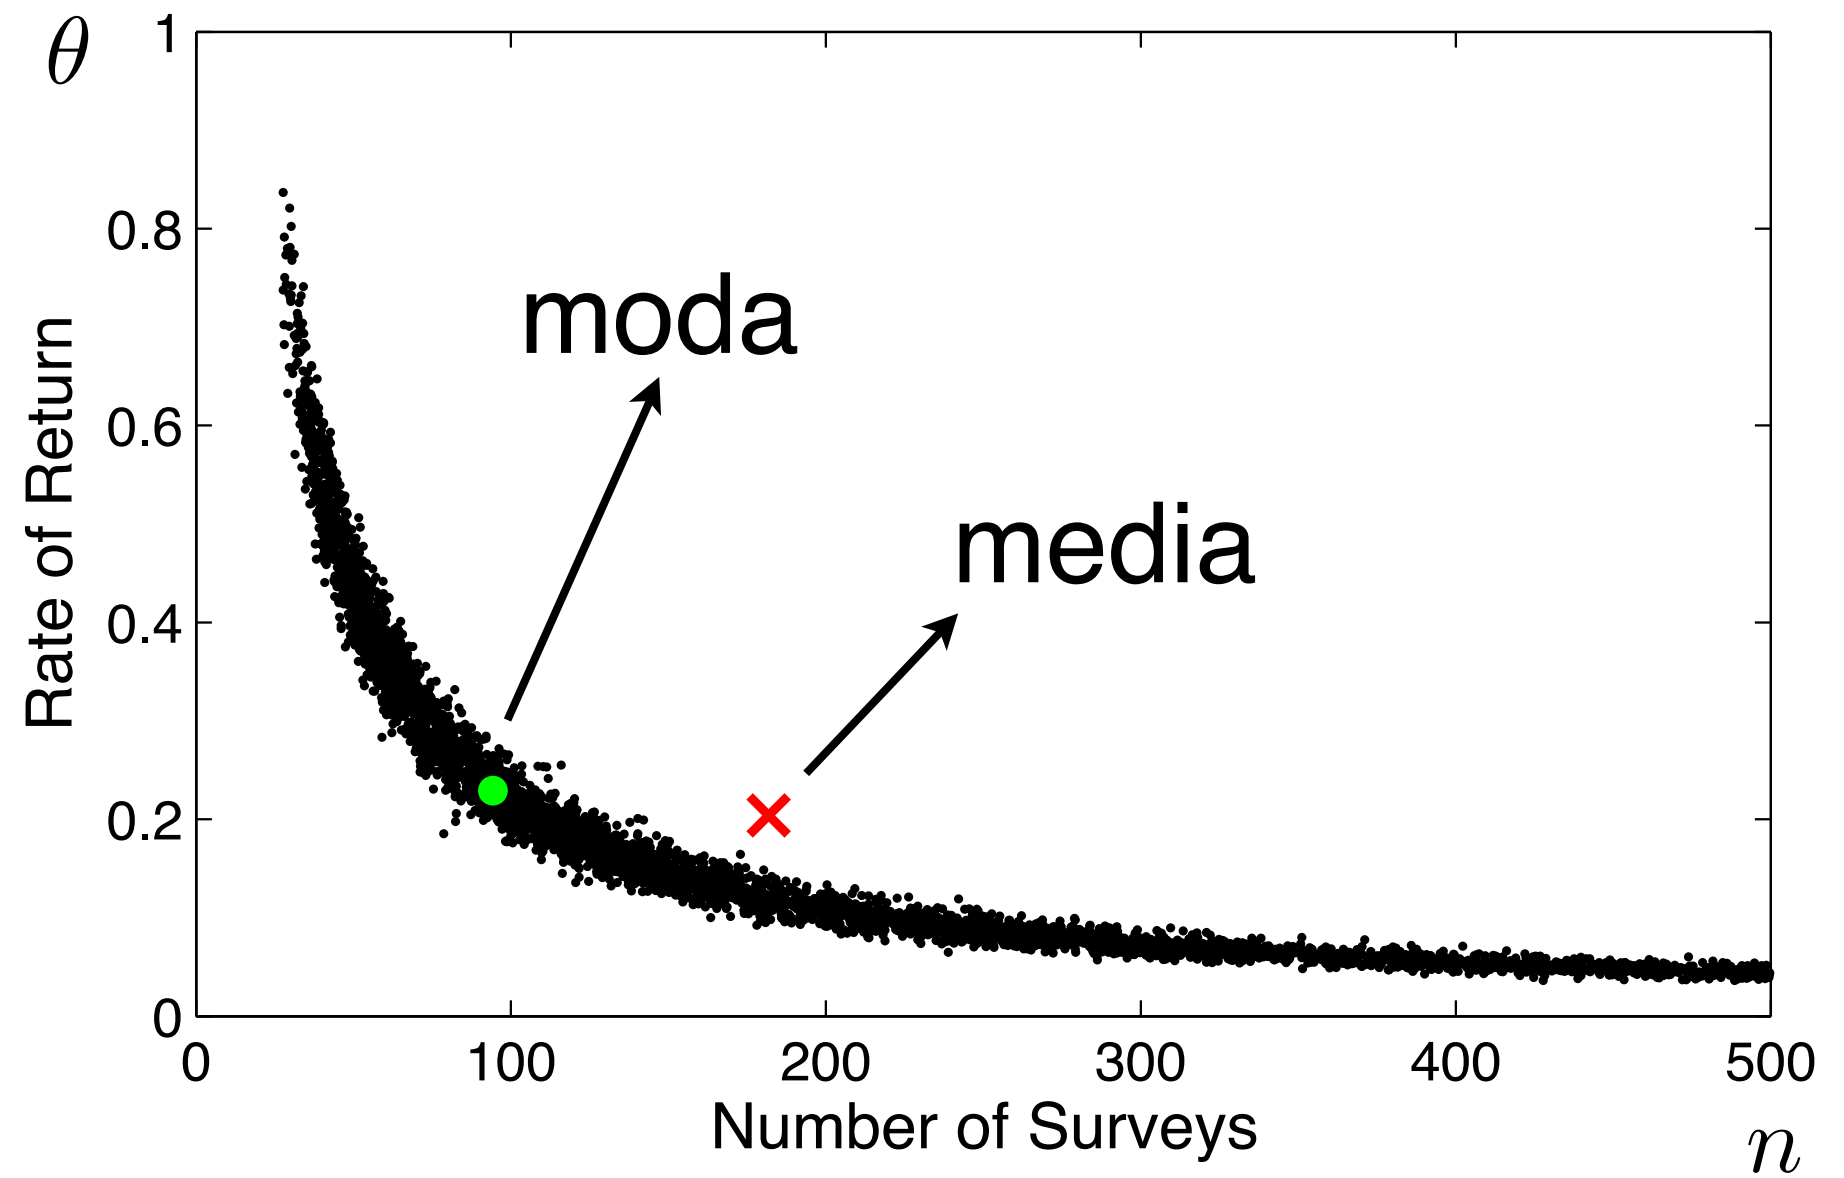

$$\theta \sim \text{Uniforme}(0, 1)$$

$$n \sim \text{Uniforme}(1, N_{max})$$

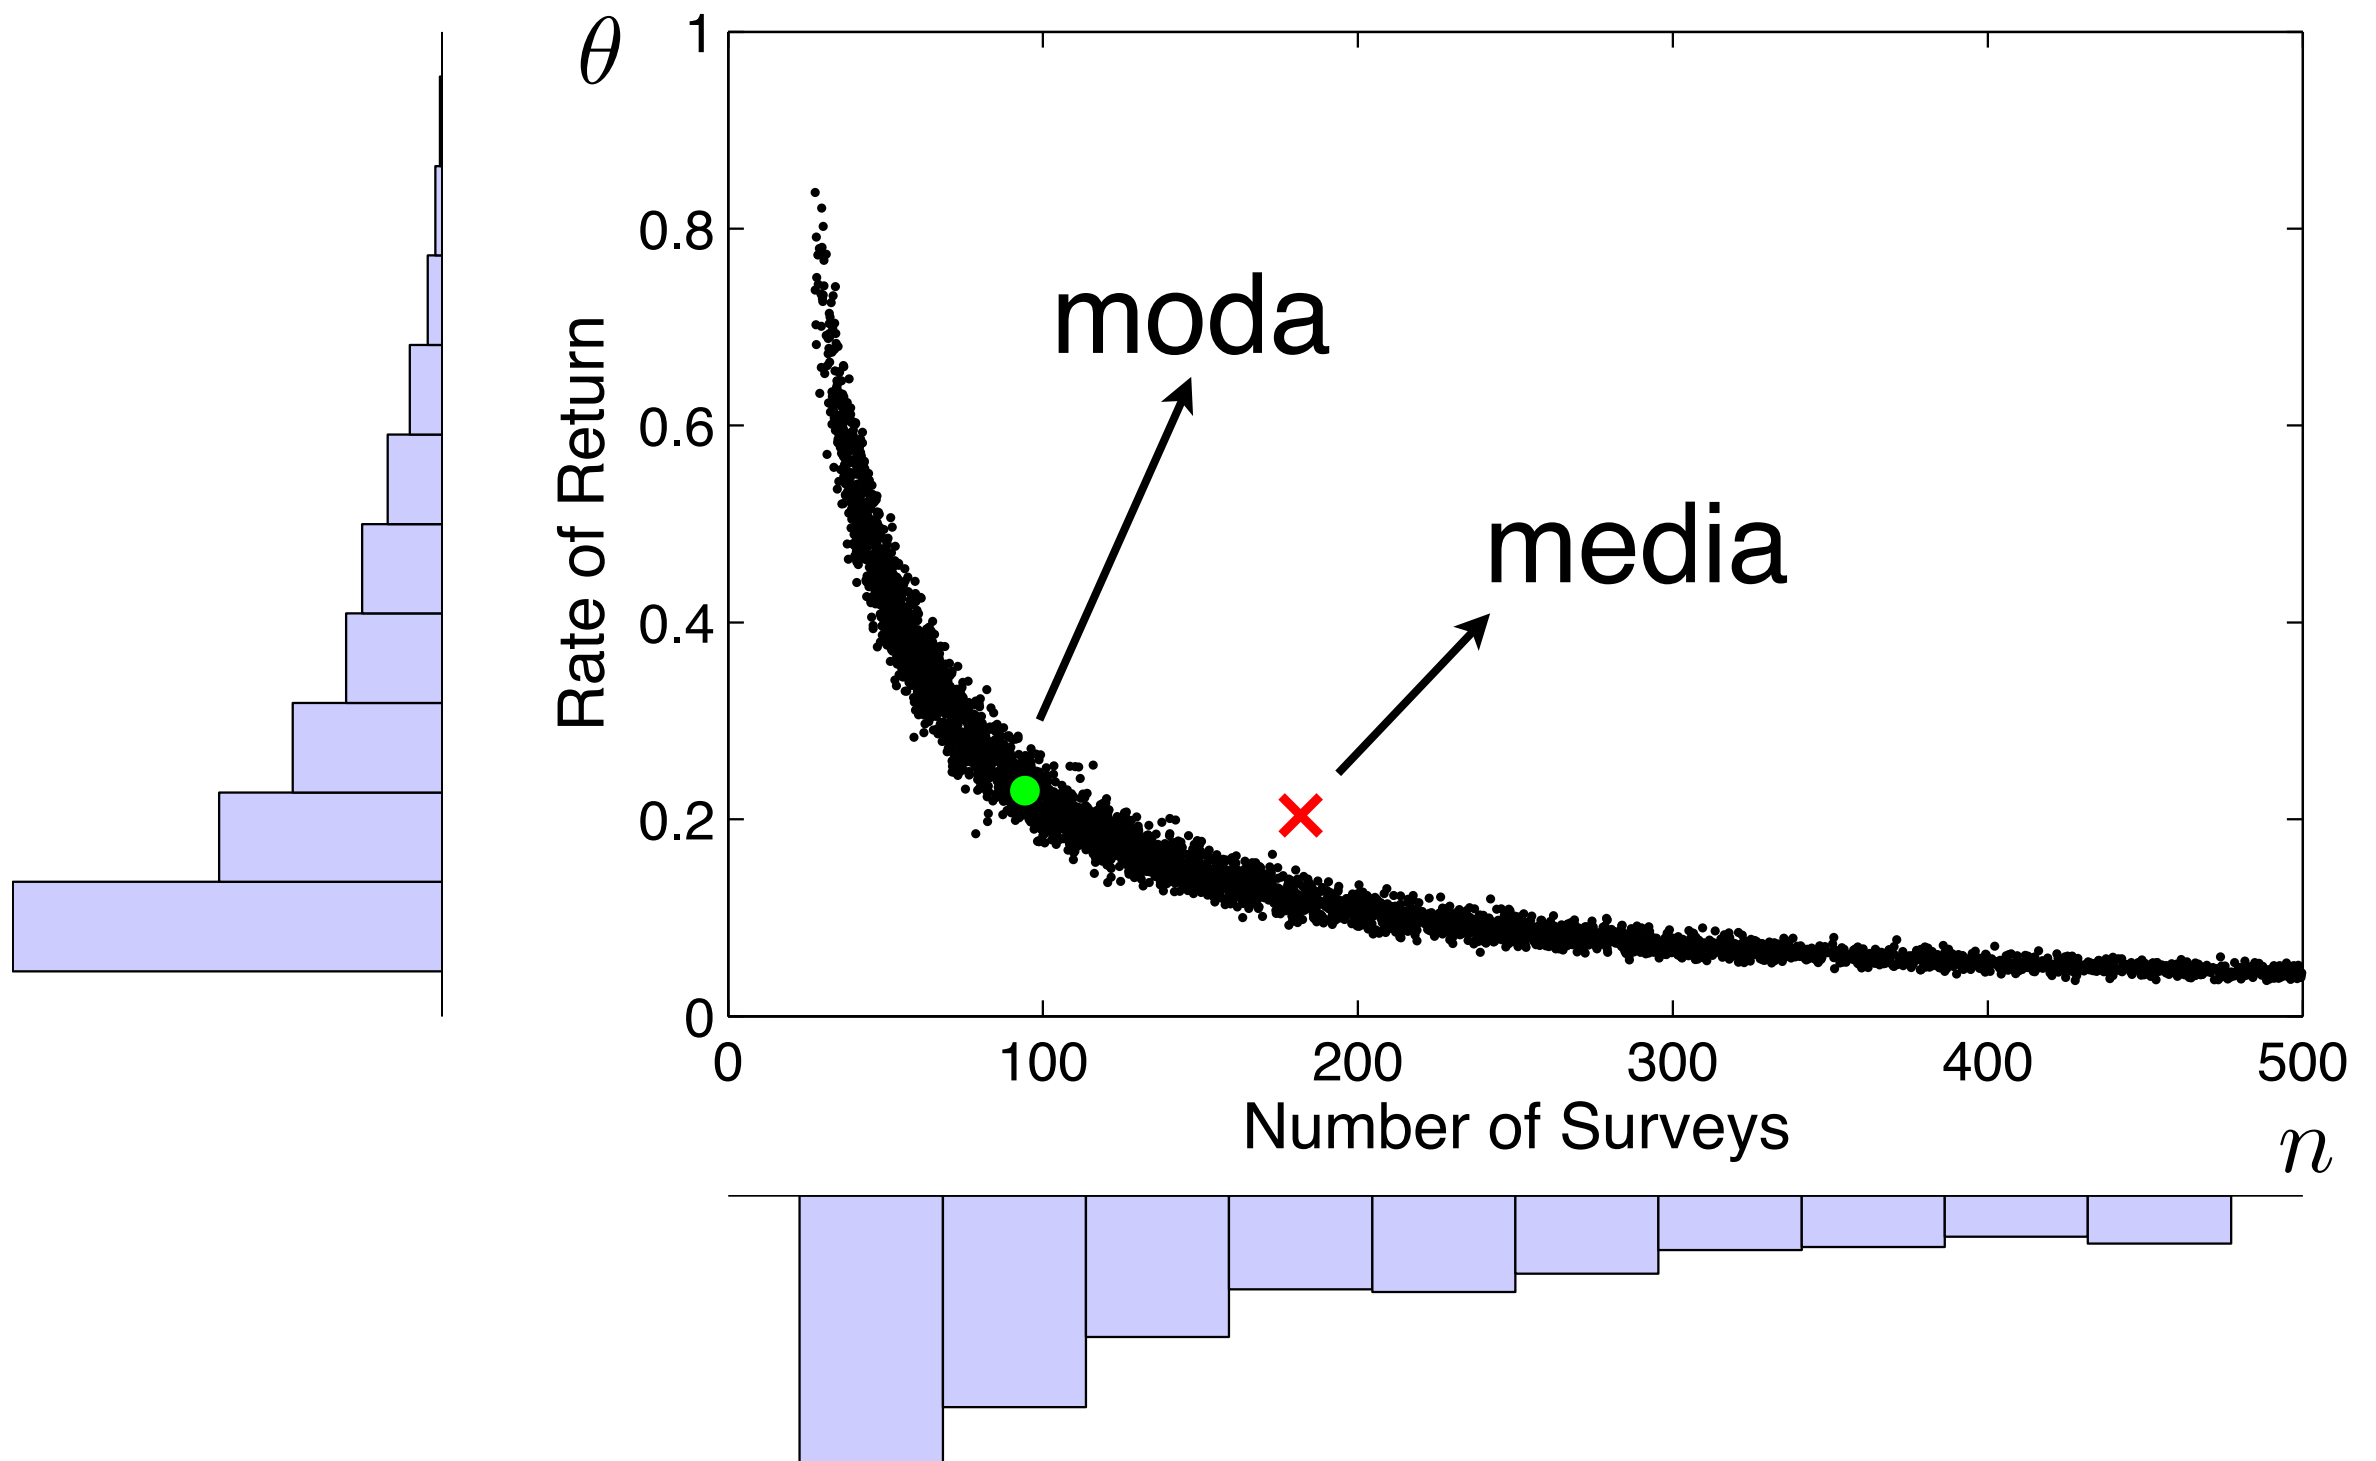
$$p(\theta, n|k) = \dots$$



$$k = \{16, 18, 22, 25, 27\}$$



$$k = \{16, 18, 22, 25, 27\}$$



¡Atención a la conjunta! (problemático con muchas variables..)


Distribución multinomial

$$\theta_1, \theta_2, \dots, \theta_k$$




$$y_1, y_2, \dots, y_k$$


Distribución multinomial



Distribución multinomial





Distribución multinomial





$$p(y|\theta) \propto \prod_{j=1}^k \theta_j^{y_j}$$

Distribución multinomial



Distribución multinomial



$$(\theta_1, \theta_2, \dots, \theta_k) = (1/6, 1/6, \dots, 1/6)$$

prior conjuado: Dirichlet

$$p(\theta|\alpha) = \text{Dirichlet}(\alpha_1, \dots, \alpha_k) \propto \prod_{j=1}^k \theta_j^{\alpha_j - 1} \quad \begin{array}{l} \theta_j \geq 0 \\ \sum_{j=1}^k \theta_j = 1 \end{array}$$

prior conjuado: Dirichlet

$$p(\theta|\alpha) = \text{Dirichlet}(\alpha_1, \dots, \alpha_k) \propto \prod_{j=1}^k \theta_j^{\alpha_j - 1}$$

$$\begin{aligned} \theta_j &\geq 0 \\ \sum_{j=1}^k \theta_j &= 1 \end{aligned}$$

posterior

$$p(\theta|y) = \text{Dirichlet}(\alpha_1 + y_1, \dots, \alpha_k + y_k)$$

prior conjuado: Dirichlet

$$p(\theta|\alpha) = \text{Dirichlet}(\alpha_1, \dots, \alpha_k) \propto \prod_{j=1}^k \theta_j^{\alpha_j - 1}$$

$$\begin{aligned} \theta_j &\geq 0 \\ \sum_{j=1}^k \theta_j &= 1 \end{aligned}$$

posterior

$$p(\theta|y) = \text{Dirichlet}(\alpha_1 + y_1, \dots, \alpha_k + y_k)$$

Análogo a
beta-binomial

prior conjuado: Dirichlet

$$p(\theta|\alpha) = \text{Dirichlet}(\alpha_1, \dots, \alpha_k) \propto \prod_{j=1}^k \theta_j^{\alpha_j - 1} \quad \begin{array}{l} \theta_j \geq 0 \\ \sum_{j=1}^k \theta_j = 1 \end{array}$$

posterior

$$p(\theta|y) = \text{Dirichlet}(\alpha_1 + y_1, \dots, \alpha_k + y_k) \quad \begin{array}{l} \text{Análogo a} \\ \text{beta-binomial} \end{array}$$

parametrización alternativa:

$$(\alpha_1, \dots, \alpha_k) \rightarrow \alpha(m_1, \dots, m_k) \quad \sum_j m_j = 1 \quad \vec{m} : \text{media}$$

prior conjuado: Dirichlet

$$p(\theta|\alpha) = \text{Dirichlet}(\alpha_1, \dots, \alpha_k) \propto \prod_{j=1}^k \theta_j^{\alpha_j - 1} \quad \begin{array}{l} \theta_j \geq 0 \\ \sum_{j=1}^k \theta_j = 1 \end{array}$$

posterior


$$p(\theta|y) = \text{Dirichlet}(\alpha_1 + y_1, \dots, \alpha_k + y_k) \quad \begin{array}{l} \text{Análogo a} \\ \text{beta-binomial} \end{array}$$

parametrización alternativa:

$$(\alpha_1, \dots, \alpha_k) \rightarrow \alpha(m_1, \dots, m_k) \quad \sum_j m_j = 1 \quad \vec{m} : \text{media}$$

α *sharpness*, cuantifica similitud de las muestras con la media
(¡análogo a la precisión!)

número de muestras para que los datos dominen sobre el *prior*



Beta(α , α)

α
0.01
1
5

Beta, Dirichlet: distribuciones sobre *distribuciones*

EJEMPLO

0.002

Los niños disfrutaron del paseo mucho más que yo.



0.002

Los niños disfrutaron del paseo mucho más que yo.

Predictibilidad: buen predictor del tiempo pasado en cada palabra en lectura



0.002

Los niños disfrutaron del paseo mucho más que yo.

Predictibilidad: buen predictor del tiempo pasado en cada palabra en lectura

Midiendo la predictibilidad de palabras

*“Voy a sacudir el mantel porque está
lleno de _____”*

Análisis de *Maximum Likelihood*

(Predictabilidad = Fracción de sujetos)

Análisis de *Maximum Likelihood*

(Predictabilidad = Fracción de sujetos)

Limitaciones:

- Sin noción de error/incerteza (10/15 ~ 100/150)
- Predictibilidad del contexto ~ predictibilidad de palabra

Análisis de *Maximum Likelihood*

(Predictabilidad = Fracción de sujetos)

Limitaciones:

- Sin noción de error/incerteza (10/15 ~ 100/150)
- Predictibilidad del contexto ~ predictibilidad de palabra

*migas migas migas migas hormigas hormigas hormigas
migas migas migas migas hormigas aceitunas árboles*

Midiendo la predictibilidad de palabras

2

Indagando más allá:

*“Voy a sacudir el mantel porque está
lleno de _____”*

Midiendo la predictibilidad de palabras

2

Indagando más allá:

*“Voy a sacudir el mantel porque está
lleno de _____”*


Análisis de *Maximum Likelihood*

(Predictabilidad = Fracción de sujetos)

Limitaciones:

- Sin noción de error/incerteza (10/15 ~ 100/150)
- Predictibilidad del contexto ~ predictibilidad de palabra
- No hace uso de palabras extra


Modelo de una palabra



$$\theta \sim \text{Dirichlet}(1, 1, \dots, 1)$$

$$w \sim \text{Categorical}(\theta_1, \theta_2, \dots, \theta_{n_{words}})$$

Modelo de una palabra




$$\theta \sim \text{Dirichlet}(1, 1, \dots, 1)$$

$$w \sim \text{Categorical}(\theta_1, \theta_2, \dots, \theta_{n_{words}})$$

- Noción de incerteza
- Predictibilidad del contexto \sim predictibilidad de palabra
- No hace uso de palabras extra

Modelo de muestreo secuencial




$$\theta \sim \text{Dirichlet}(1, 1, \dots, 1)$$

$$w_1 \sim \text{Categorical}(\theta_1, \theta_2, \dots, \theta_{n_{words}})$$

$$w_2 \sim \text{Categorical}(\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_{n_{words}})$$

$$w_3 \sim \text{Categorical}(\tilde{\tilde{\theta}}_1, \tilde{\tilde{\theta}}_2, \dots, \tilde{\tilde{\theta}}_{n_{words}})$$

Modelo de muestreo secuencial



$$\theta \sim \text{Dirichlet}(1, 1, \dots, 1)$$

$$w_1 \sim \text{Categorical}(\theta_1, \theta_2, \dots, \theta_{n_{words}})$$

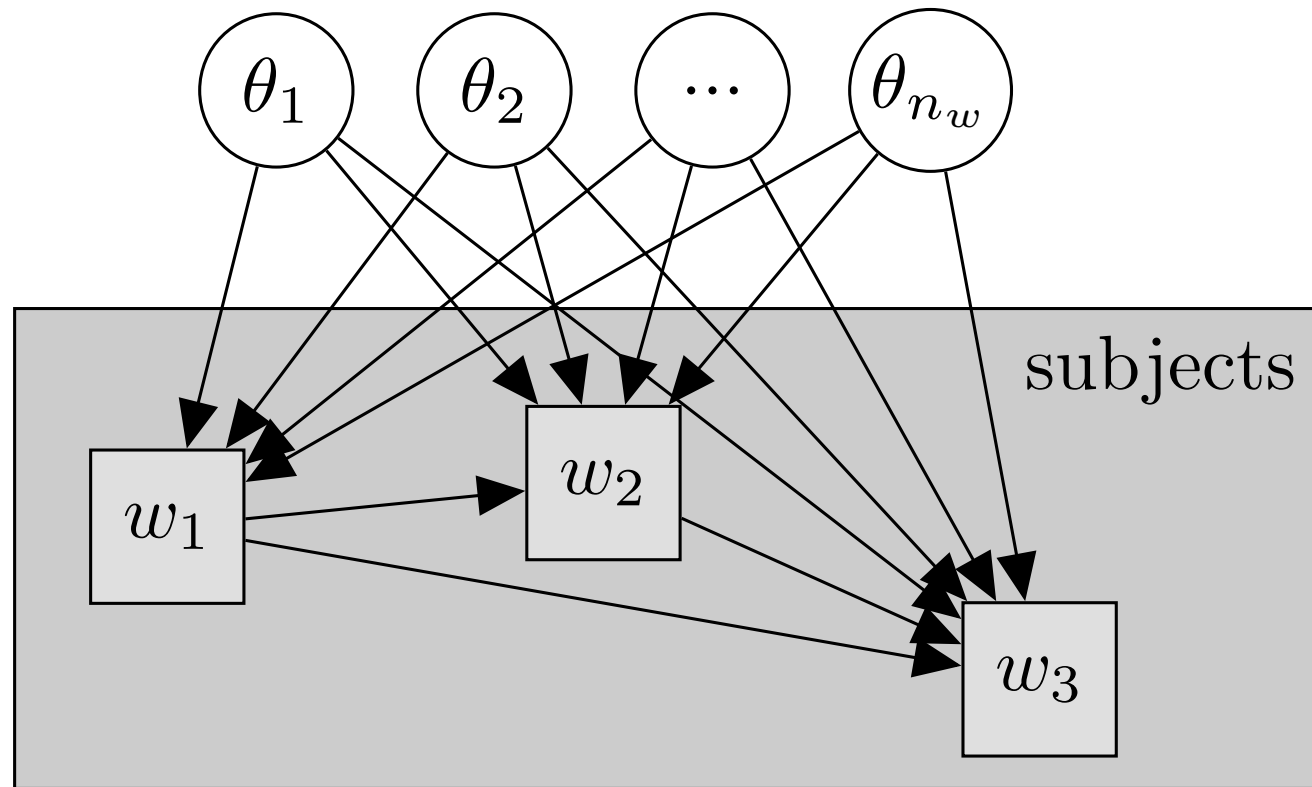
$$w_2 \sim \text{Categorical}(\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_{n_{words}})$$

$$w_3 \sim \text{Categorical}(\tilde{\tilde{\theta}}_1, \tilde{\tilde{\theta}}_2, \dots, \tilde{\tilde{\theta}}_{n_{words}})$$

$$\tilde{\theta}_i = \begin{cases} \frac{\theta_i}{1 - \theta_{w_1}} & \text{if } i \neq w_1 \\ 0 & \text{if } i = w_1 \end{cases}$$

$$\tilde{\tilde{\theta}}_i = \begin{cases} \frac{\tilde{\theta}_i}{1 - \tilde{\theta}_{w_2}} & \text{if } i \neq w_2 \\ 0 & \text{if } i = w_2 \end{cases}$$

Modelo de muestreo secuencial



$$\theta \sim \text{Dirichlet}(1, 1, \dots, 1)$$

$$w_1 \sim \text{Categorical}(\theta_1, \theta_2, \dots, \theta_{n_{words}})$$

$$w_2 \sim \text{Categorical}(\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_{n_{words}})$$


$$w_3 \sim \text{Categorical}(\tilde{\tilde{\theta}}_1, \tilde{\tilde{\theta}}_2, \dots, \tilde{\tilde{\theta}}_{n_{words}})$$

$$\tilde{\theta}_i = \begin{cases} \frac{\theta_i}{1 - \theta_{w_1}} & \text{if } i \neq w_1 \\ 0 & \text{if } i = w_1 \end{cases}$$

$$\tilde{\tilde{\theta}}_i = \begin{cases} \frac{\tilde{\theta}_i}{1 - \tilde{\theta}_{w_2}} & \text{if } i \neq w_2 \\ 0 & \text{if } i = w_2 \end{cases}$$

- Noción de incerteza
- Predictibilidad del contexto ~ predictibilidad de palabra
- Usa palabras extra

Modelo de muestreo secuencial



$$\theta \sim \text{Dirichlet}(1, 1, \dots, 1)$$

$$w_1 \sim \text{Categorical}(\theta_1, \theta_2, \dots, \theta_{n_{\text{words}}})$$

$$w_2 \sim \text{Categorical}(\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_{n_{\text{words}}})$$

$$w_3 \sim \text{Categorical}(\tilde{\tilde{\theta}}_1, \tilde{\tilde{\theta}}_2, \dots, \tilde{\tilde{\theta}}_{n_{\text{words}}})$$

$$\tilde{\theta}_i = \begin{cases} \frac{\theta_i}{1 - \theta_{w_1}} & \text{if } i \neq w_1 \\ 0 & \text{if } i = w_1 \end{cases}$$

$$\tilde{\tilde{\theta}}_i = \begin{cases} \frac{\tilde{\theta}_i}{1 - \tilde{\theta}_{w_2}} & \text{if } i \neq w_2 \\ 0 & \text{if } i = w_2 \end{cases}$$

- Noción de incerteza

- Predictibilidad del contexto ~ predictibilidad de palabra

- Usa palabras extra

Modelos jerárquicos